

Prédiction des émissions carbone d'un portefeuille automobile multi-marchés européen

Arthur Filippi

École Polytechnique, CMAP (Centre de Mathématiques Appliquées)
arthur.filippi@polytechnique.edu

Abstract

Measuring the carbon footprint of asset portfolios has become both a regulatory (CSRD, EU green taxonomy) and a strategic requirement for financial institutions. For a vehicle-financing portfolio, this footprint depends first and foremost on the *carbon intensity* (gCO₂/km) of the financed vehicles, a homologation quantity that is frequently missing from management databases. We tackle its prediction on a real, heterogeneous, multi-country dataset (seven European markets, $\approx 800k$ observations) that is far removed from the clean, single-source homologation datasets typically used in the literature. We propose a complete, auditable machine-learning chain : (i) fuzzy-matching imputation of missing technical features, whose distributional impact is controlled via Jensen-Shannon divergence and Wasserstein distance ; (ii) a four-model benchmark (LightGBM in two feature scopes, XGBoost, an MLP) under 5-fold cross-validation, where SHAP analysis serves as a diagnostic tool and motivates a feature-scope reduction that curbs overfitting ; (iii) distribution-free conformal prediction intervals (MAPIE), directly usable for bounded reporting ; and (iv) a cross-market transferability study via a domain classifier, a PCA-based cluster analysis and covariate-shift AUCs, establishing strong covariate shift but no concept shift, hence correctable by importance reweighting. Throughout, explainability and auditability are treated as first-class constraints, on par with predictive accuracy.

1 Contexte et cadre méthodologique

Enjeux. La mesure de l’empreinte carbone des portefeuilles d’actifs est devenue une exigence réglementaire (CSRD, taxonomie verte européenne) et stratégique pour les institutions financières. Pour un portefeuille de financement automobile, l’objectif est double : produire une estimation fiable et *bornée* de l’empreinte agrégée à des fins de reporting, et fournir une méthodologie reproductible, explicable et transférable, auditable et réappropriable par des équipes internes. Un modèle précis mais opaque, non généralisable ou inapplicable aux données réelles serait sans valeur opérationnelle. C’est la tension entre rigueur statistique et exploitabilité qui structure nos choix : l’explicabilité (SHAP, §2.2.1) et la quantification d’incertitude (prédiction conforme, §2.3.4) sont traitées comme des contraintes de premier ordre. À l’échelle d’un portefeuille de plusieurs centaines de milliers de véhicules, une erreur systématique même faible sur l’intensité se propage en un biais agrégé important sur l’empreinte déclarée ; la précision *et* la maîtrise de l’incertitude associée sont donc indissociables.

Données et découplage. Le portefeuille couvre sept marchés européens, avec des taux de complétude et des conventions d’encodage variables d’un marché à l’autre. L’empreinte annuelle d’un véhicule se factorise en

$$E_{\text{CO}_2} = D_{\text{annuelle}} \times I_{\text{carbone}}, \quad (1)$$

où I_{carbone} (gCO₂/km) dépend des caractéristiques physico-techniques et est mesurée à l’homologation, tandis que D_{annuelle} dépend de l’usage. Ces déterminants sont disjoints, ce qui autorise une prédiction séparée. L’intensité étant partiellement présente dans les données (la distance, elle,

en est absente), nous concentrons ce travail sur I_{carbone} ; la prédiction de D_{annuelle} est un prolongement hors périmètre.

État de l’art. La prédiction des émissions de CO₂ par des méthodes de ML connaît une littérature croissante depuis 2020, mais hétérogène. Deux familles de problèmes coexistent : la prédiction à partir des caractéristiques techniques statiques du véhicule, et la prédiction d’émissions instantanées à partir de données dynamiques de conduite (vitesse, accélération, pente) [20]. Les conclusions divergent : le gradient boosting (XGBoost, LightGBM, CatBoost) domine généralement sur données tabulaires statiques [13, 5], mais certains travaux privilégient des réseaux de neurones dédiés [1], et beaucoup de comparaisons sont biaisées par des *features* circulaires (typiquement la consommation de carburant mesurée, utilisée comme prédicteur des émissions alors qu’elle est indisponible dans un contexte bancaire). Plus fondamentalement, les jeux de données employés sont presque exclusivement des bases d’homologation publiques (Canada, Royaume-Uni, Union européenne), propres, complètes et mono-sources, sans rapport avec un portefeuille bancaire multi-pays, hétérogène, à fort taux de valeurs manquantes et aux conventions d’encodage variables. Le *dataset shift* entre marchés, pourtant critique dès lors qu’on envisage un modèle international, n’est traité dans aucun des travaux identifiés ; quant à la distance annuelle, les rares approches existantes reposent sur des données télémétriques embarquées [11] ou des enquêtes de mobilité, inaccessibles dans notre cadre. C’est précisément dans ces angles morts, robustesse aux données dégradées, généralisation multi-marchés, quantification de l’incertitude, que se situent nos contributions.

2 Prédiction de l'intensité carbone

2.1 Pré-traitement et imputation

Harmonisation et outliers. Les données proviennent de bases nationales hétérogènes, chacune avec ses conventions pour les labels catégoriels (notamment FUEL_TYPE) et continus (HORSEPOWER, exprimée en chevaux mécaniques ou fiscaux selon le pays), qu'il faut d'abord normaliser vers un référentiel commun. Les valeurs aberrantes sont ensuite éliminées ($\text{CO}_2 > 500 \text{ gCO}_2/\text{km}$, incompatible avec les normes WLTP/NEDC, ou ENGINE_SIZE manifestement incohérente avec les autres caractéristiques).

Imputation des features manquantes. Les champs ENGINE_SIZE (cylindrée) et ENGINE_WEIGHT (masse à vide) présentent un taux de valeurs manquantes non négligeable, particulièrement sur les véhicules anciens et dans certains pays. Ils comptent parmi les *features* les plus prédictives (cf. SHAP, §2.2.1) : leur absence dégraderait fortement la couverture du modèle. Or ces grandeurs sont quasi-déterministes au sein d'un cluster (BRAND, MODEL), un même modèle commercial n'existe qu'en un petit nombre de motorisations. La variance intra-groupe y est faible devant la variance inter-groupes (Fig. 1) : la moyenne conditionnelle à (BRAND, MODEL) est donc un estimateur à faible biais. Cette hypothèse est en outre validée par une procédure de masquage : on cache artificiellement une fraction de valeurs observées, on les impute, puis on compare à la vérité terrain, en complément des métriques distributionnelles ci-dessous. Le pipeline opère en deux temps : (i) *fuzzy matching*, on construit un dictionnaire associant à chaque clé (BRAND, MODEL) la moyenne observée, et l'on impute via la clé la plus proche au sens de la distance de Levenshtein (au-delà d'un seuil de similarité); (ii) *fallback* sur la moyenne conditionnelle à BRAND ou FUEL_TYPE en l'absence de correspondance suffisante.




FIG. 1. Validation de l'imputation : dispersion intra-cluster de ENGINE_SIZE et ENGINE_WEIGHT au sein des groupes (BRAND, MODEL). La faible variance intra-cluster, devant la variance inter-groupes, justifie l'imputation par la moyenne conditionnelle.

Contrôle distributionnel. Pour vérifier que l'imputation ne déforme pas les distributions, exigence d'auditabilité, on compare l'avant (P) et l'après (Q) imputation par deux métriques complémentaires. La divergence de Jensen-Shannon, extension symétrique de Kullback-Leibler,

$$\text{JS}(P\|Q) = \frac{1}{2}\text{KL}(P\|M) + \frac{1}{2}\text{KL}(Q\|M), \quad M = \frac{P+Q}{2}, \quad (2)$$

mesure la dissimilarité (proche de 0 : pas de déformation). La distance de Wasserstein, $W_1(P, Q) = \inf_{\gamma \in \Gamma(P, Q)} \mathbb{E}_{(x, y) \sim \gamma} |x - y|$, sensible à la géométrie de l'espace, pénalise les déplacements de masse proportionnellement à leur amplitude et renseigne donc sur l'*ampleur* des biais. On retient $\text{JS} < 0.05$ et W_1 sous 5 % de l'écart interquartile comme seuils d'acceptabilité. Les résultats (Table 1) sont satisfaisants : à l'exception de ENGINE_SIZE en Espagne (5.44 % imputés, $W_1 = 15.12$), les déformations restent marginales.

TAB. 1. Taux de valeurs manquantes imputées par marché, et métriques de contrôle distributionnel (WGT = ENGINE_WEIGHT, SIZE = ENGINE_SIZE).

Pays	Obs.	WGT	JS	W_1	SIZE	JS	W_1
All.	48 246	1.94%	9×10^{-5}	4.98	0.38%	2×10^{-4}	2.15
Fra.	199 823	2.43%	2×10^{-5}	2.30	2.42%	3×10^{-4}	3.94
Ita.	236 643	1.24%	5×10^{-5}	2.30	1.24%	3×10^{-5}	2.86
Por.	—	—	—	—	—	—	—
Spa.	308 381	2.38%	5×10^{-4}	3.89	5.44%	4×10^{-3}	15.12

Analyse exploratoire. Avant toute modélisation, l'examen des densités empiriques oriente trois choix structurants. (i) *Symétrie*. CO_2WLTP est relativement symétrique et peut être traitée telle quelle; HORSEPOWER a une queue lourde, mais imputable à des outliers résiduels; ENGINE_SIZE se concentre autour de quelques noyaux (cylindrées standardisées), un découpage net qui plaide pour des modèles à arbres. (ii) *Hétérogénéité inter-marchés*. Les distributions de ENGINE_SIZE et CO_2WLTP varient substantiellement entre marchés, tout comme le mix de carburants (pénétration des électriques EL et hybrides MX) : c'est le principal facteur de *dataset shift* analysé en §3. (iii) En revanche, la distribution jointe HORSEPOWER-ENGINE_SIZE est similaire entre marchés et présente des clusters nets, exploitables par apprentissage.




FIG. 2. Analyse exploratoire (marché allemand) : densités des variables techniques et mix de carburants.

2.2 Modèles et explicabilité

Nous comparons quatre modèles (Table 2) : LightGBM [6] en deux périmètres de *features* (*full* et *light scope*), XGBoost [2], et un MLP. Les fondements détaillés (boosting au second ordre, optimiseur Adam, différences algorithmiques entre LightGBM et XGBoost) sont rassemblés en annexe A.

TAB. 2. Caractéristiques des quatre modèles comparés.

Détails	Model 1	Model 2	XGB	MLP
Algorithme	LightGBM	LightGBM	XGBoost	MLP
Features	full ^a	light ^b	light	light
n_estim.	3000	3000	3000	500
lr	0.05	0.05	0.05	10 ⁻³
max_depth	6	4	6	—
num_leaves	31	15	—	—
min_child	20	50	5	—
Archi.	—	—	—	(128,64)
Early stop.	50	50	50	20

^a BRAND, MODEL, NEW_2HAND, FUEL_TYPE, ENGINE_WEIGHT, ENGINE_SIZE, HORSEPOWER.

^b FUEL_TYPE, ENGINE_WEIGHT, ENGINE_SIZE, HORSEPOWER.

2.2.1 SHAP et auditabilité

Le cahier des charges impose une **méthodologie auditable** : chaque prédiction doit pouvoir être justifiée et vérifiée par un tiers (régulateur, auditeur, équipe métier), faute de quoi le modèle, si précis soit-il, est inexploitable en production. Les SHAP values [9, 16] fournissent précisément ce levier d'auditabilité. Issues de la théorie des jeux coopératifs, elles répondent à la question : si plusieurs « joueurs » (les *features*) coopèrent pour produire un gain (la prédiction), quelle est la contribution équitable de chacun [10]? La contribution de la *feature j* sur l'observation *x* est

$$\phi_j(f, x) = \sum_{S \subseteq N \setminus \{j\}} \frac{|S|!(|N| - |S| - 1)!}{|N|!} [f_x(S \cup \{j\}) - f_x(S)], \quad (3)$$

avec $f_x(S) = \mathbb{E}[f(X) \mid X_S = x_S]$: c'est le gain marginal moyen apporté par *j*, moyenné sur tous les sous-ensembles *S* d'autres *features*. Les SHAP sont l'unique attribution satisfaisant les axiomes d'efficacité, symétrie, linéarité et joueur nul, ce qui les distingue des mesures heuristiques d'importance. Leur calcul exact, exponentiel en général, devient tractable sur les modèles à arbres grâce à l'algorithme TreeSHAP, en $O(TLD^2)$ pour *T* arbres de profondeur *D* et *L* feuilles, un point décisif pour auditer un modèle sur l'ensemble d'un portefeuille. Le *beeswarm plot* visualise la distribution des ϕ_j sur le jeu de validation, colorée par la valeur de la *feature* : il révèle d'un coup d'œil l'importance globale, le sens et la monotonie de chaque effet (un HORSEPOWER élevé pousse la prédiction vers le haut, etc.). Au-delà de l'audit *a posteriori*, nous utilisons SHAP comme outil de *diagnostic* actif pour la sélection de modèle (§2.3) : c'est l'inspection des contributions qui révèle quelles *features* nuisent au modèle.

2.3 Résultats comparatifs

2.3.1 Une première approche : régression *k*-NN

Nous avons d'abord cherché à exploiter la similarité locale : deux véhicules mécaniquement proches devraient émettre des quantités de CO₂ proches, et un estimateur local non paramétrique pourrait capter cette relation sans hypothèse paramétrique sur sa forme. La principale difficulté est la définition d'une distance sur un espace mixte numérique-catégoriel. Pour éviter un *one-hot encoding*

arbitraire, nous adoptons la distance de Gower, qui normalise les *features* numériques par leur étendue et traite FUEL_TYPE par une distance 0/1, avec un hyperparamètre *w* contrôlant le poids relatif de FUEL_TYPE. La sélection est conduite par recherche sur grille $(k, w) \in \{2, 3, 4, 5, 6, 7, 10, 20\} \times \{0.25, 0.5, 1, 2, 4\}$, sur un jeu test de 3000 observations (entraînement limité à 4000 pour contenir le coût quadratique de la matrice de Gower).




FIG. 3. Régression *k*-NN (distance de Gower) : RMSE en fonction de (k, w) . Le comportement diffère radicalement d'un marché à l'autre, ce qui décourage toute généralisation.

Sur l'Allemagne (Fig. 3a), la RMSE croît de façon monotone avec *k*, sans minimum local : la meilleure configuration (*k*=2, *w*=0.5) atteint 7.34 g/km, contre 7.27 g/km pour LightGBM *light-scope*. Cette performance, bonne dans l'absolu, n'est en rien informative du pouvoir de généralisation, et un *k* aussi faible est peu robuste. La contre-vérification sur un second marché (Fig. 3b) révèle un comportement radicalement différent : la RMSE décroît puis croît avec un minimum intérieur peu marqué autour de *k*=6, et *w* n'a quasiment aucun effet (signe que FUEL_TYPE est déjà séparé dans l'espace numérique); la meilleure RMSE y est de 21.8 g/km, soit 4.38 g/km au-dessus de LightGBM. Ce résultat est paradoxal car les voisinages sont effectivement locaux : le ratio $\bar{d}_{k_{opt}}/\text{diam}(\mathcal{X})$ vaut 0.03 et 0.01 sur les deux marchés, c'est-à-dire que les *k*_{opt} plus proches voisins couvrent moins de 3 % et 1 % du diamètre de l'espace. L'explication tient à la structure *discrète* des données : l'espace n'est pas un continuum régulier mais un ensemble de clusters séparés par des frontières nettes (électriques vs. thermiques, grosses cylindrées vs. reste du parc). Dans ces zones de transition, deux voisins au sens de Gower peuvent avoir des intensités très différentes, rendant la moyenne des voisins peu informative, là, précisément, où un arbre de décision excelle en faisant de ces frontières

des splits prioritaires. La localité est donc nécessaire mais non suffisante : encore faut-il que la cible soit *régulière* dans le voisinage, ce qui n'est pas le cas. La variante différentielle DNNR [12], qui corrige les discontinuités via un développement de Taylor local, ne s'applique pas à cette topologie. Le k -NN est donc écarté : peu auditable (interpoler une émission par deux voisins est inacceptable en contexte bancaire), instable entre marchés, et coûteux en scan linéaire sur un jeu aussi large.

2.3.2 Changement de paradigme : modèles à arbres

Les frontières nettes des données appellent une architecture à arbres de décision. Nous avons procédé par tâtonnement, d'un modèle généraliste vers des variantes plus parcimonieuses, puis un MLP de contrôle. Les résultats portent sur l'Allemagne (base la plus propre; BELGIUM et NETHERLANDS sont inexploitable, des *features* y étant absentes). Quatre critères guident la sélection : la **précision** (RMSE en validation croisée), le **risque d'overfitting** (écart train/validation), la **fidélité géométrique** (heatmaps de CO₂ dans un plan de *features*, qui doivent ne pas sur- ou sous-charger de régions et restituer la nullité des électriques) et l'**explicabilité** (SHAP). Les résultats quantitatifs complets sont en Table 3 ; les heatmaps de cohérence de chaque modèle sont reportées en annexe B.

TAB. 3. Performances des quatre modèles sur l'Allemagne (cibles WLTP et NEDC). h.-o. : hold-out.


Grandeur	M1	M2	XGB	MLP
<i>Cible : CO₂ WLTP</i>				
Train RMSE (h.-o.)	3.39	6.37	4.22	11.93
Val RMSE (h.-o.)	5.21	7.32	5.90	11.94
Gap (val—train)	1.82	0.95	1.68	0.01
CV RMSE ($\pm$ std)	5.56 $\pm$.32	7.27 $\pm$.23	5.73 $\pm$.23	13.06 $\pm$.44
CV MAE	2.94	4.36	2.94	$\sim$ 9.5
CV R^2	.9911	.9860	.9913	$\sim$.92
IC 95% ($\pm$ g/km)	11	14	11	26
<i>Cible : CO₂ NEDC</i>				
Train RMSE (h.-o.)	7.37	9.57	6.17	14.76
Val RMSE (h.-o.)	12.74	11.02	9.73	14.50
Gap (val—train)	5.37	1.45	3.56	-0.26
CV RMSE ($\pm$ std)	13.73 $\pm$ 1.3	10.99 $\pm$.14	9.68 $\pm$.23	15.29 $\pm$.29
CV MAE	8.71	7.44	5.80	11.22
CV R^2	.8996	.9349	.9495	.8742
IC 95% ($\pm$ g/km)	27	22	19	30

Model 1 (full-scope). Le modèle présente un overfitting significatif, exacerbé en NEDC (gap validation—train de 1.82 en WLTP, 5.37 en NEDC). Les SHAP (Fig. 4) en révèlent l'origine : les contributions de NEW_2HAND, BRAND et MODEL sont très ramassées et sans pattern directionnel, là où les variables mécaniques suivent un pattern logique (une faible cylindrée, masse ou puissance abaisse la prédiction, une valeur élevée l'augmente; FUEL_TYPE, catégoriel, forme des clusters nets, compacts et disjoints). Ces trois *features* sont en effet dangereuses à plus d'un titre. D'abord, elles sont au mieux inutiles : l'intensité des bases est une valeur en sortie d'usine, donc NEW_2HAND (neuf/occasion) ne doit pas la modifier. Ensuite, elles sont


dangereusement redondantes : marque et modèle n'agissent sur les émissions qu'à travers les caractéristiques physiques (cylindrée, masse, puissance) déjà présentes. Enfin, BRAND et MODEL sont à haute cardinalité (des centaines de labels) : à chaque nœud, l'arbre évalue des centaines de splits candidats, ce qui augmente la probabilité de trouver un bon split *par hasard* sur l'échantillon d'entraînement, même en l'absence de pouvoir prédictif réel. Contrairement à l'intuition «plus de variables = meilleure prédiction», cela accroît l'overfitting si ces variables ne sont que du bruit.

Model 2 (light-scope). À la lumière de ce diagnostic, nous éliminons les variables sans intérêt. Les performances sont nettement meilleures : l'overfitting est bien moindre, l'erreur à peine plus élevée en WLTP mais inférieure en NEDC, et toujours très satisfaisante. Les SHAP (Fig. 5) sont rassurantes, à pattern directionnel clair, avec des clusters fortement marqués (cluster électrique sur FUEL_TYPE et ENGINE_SIZE). Les heatmaps (annexe B) confirment le respect de la géométrie initiale : les régions de très faible intensité (électriques, cylindrée nulle), de très forte intensité (grosses cylindrées, caractéristiques du marché allemand) et les régions intermédiaires sont fidèlement restituées. Ces heatmaps ont une vertu heuristique : elles localisent les zones mal prédites sans constituer une preuve absolue. Model 2 réalise le meilleur compromis biais-variance et répond au besoin d'auditabilité.

XGBoost et MLP. Les deux autres modèles confirment ce choix. XGBoost (Fig. 6) atteint une RMSE finale plus basse mais réintroduit un overfitting non négligeable, voire prononcé; ses SHAP montrent que HORSEPOWER perd du pouvoir prédictif en NEDC tandis que FUEL_TYPE en gagne, le pattern directionnel restant globalement conservé. De manière générale, LightGBM surpasse XGBoost grâce à sa croissance *leaf-wise* : il identifie et approfondit en priorité les feuilles les plus informatives (la discontinuité des électriques, CO₂ $\approx$ 0), tandis que la croissance *level-wise* de XGBoost dilue le budget de splits sur des régions déjà bien expliquées. Le MLP, malgré un *tuning* intensif des *features*, sous-apprend systématiquement : sa précision est très dégradée. Cela confirme la supériorité connue des arbres sur données tabulaires [17]. [4] en donne deux explications. D'une part, les MLP sont biaisés vers des fonctions cibles régulières (biais spectral vers les basses fréquences [15]) : Adam réduit d'abord l'erreur globale, et apprend exponentiellement plus difficilement les variations locales, or nos cibles varient violemment (un hybride de 300 ch peut émettre 30 g/km, un thermique de mêmes puissance et cylindrée jusqu'à 200 g/km). D'autre part, les MLP sont invariants par rotation : chaque neurone combine linéairement toutes les *features*, si bien qu'une *feature* peu informative perturbe l'apprentissage des vrais prédicteurs; [14] montre que la complexité d'échantillon de tout algorithme invariant par rotation croît linéairement avec le nombre de *features* inutiles, là où les arbres, évaluant chaque *feature* séparément, y sont structurellement immunisés. **Au total, Model 2 est retenu.**




(a) Learning curve.




(b) Beeswarm SHAP.

FIG. 4. Model 1 (full-scope), Allemagne, cible WLTP. Overfitting visible ; BRAND, MODEL, NEW_2HAND présentent des contributions SHAP ramassées et non directionnelles.




(a) Learning curve.




(b) Beeswarm SHAP.

FIG. 5. Model 2 (light-scope), Allemagne, cible WLTP. Overfitting jugulé, contributions directionnelles et lisibles (cluster électrique net sur FUEL_TYPE et ENGINE_SIZE).



(a) Learning curve.



(b) Beeswarm SHAP.

FIG. 6. XGBoost (light-scope), Allemagne, cible WLTP. RMSE finale plus basse, mais overfitting réintroduit.

2.3.3 Comparaison inter-marchés

Nous étendons la comparaison aux marchés exploitables (Table 4). *Cohérence des métriques* : les écarts-types inter-plis sont faibles (sous 6% de la RMSE moyenne), signe d'une bonne stabilité; le ratio RMSE/MAE relativement élevé signale quelques prédictions à forte erreur, vraisemblablement des configurations atypiques (hybrides rechargeables) que les quatre *features light-scope* ne capturent pas parfaitement. *Comparaison inter-modèles* : XGBoost produit la RMSE la plus basse en Espagne (WLTP et NEDC), parfois avec un avantage marqué, mais toujours au prix d'un overfitting non négligeable; Model 2 réalise le meilleur compromis biais-variance et domine sur l'Allemagne. Le MLP est systématiquement le moins performant, avec une RMSE de 1.3 à 1.8× celle de Model 2; la seule quasi-exception est l'Espagne WLTP (MLP 9.32 vs. Model 2 9.42), où le grand effectif (159 142 obs.) compense partiellement le biais spectral, l'écart MLP/arbres se réduisant avec la taille du jeu, comme l'annonçait [4]. *Comparaison inter-marchés* : contre l'intuition, la taille du jeu ne réduit pas significativement l'erreur (les arbres fonctionnent dès que $\#obs \gg \#features$, toujours vérifié ici); en revanche les parcs diffèrent en homogénéité, certains présentant plus de variance et des secteurs isolés mal prédits. Surtout, **le même modèle (Model 2) s'impose quel que soit le marché**, ce qui est rassurant opérationnellement : les différences structurelles ne justifient pas d'entraîner des types de modèles distincts par pays. *WLTP vs. NEDC* : la norme NEDC, plus ancienne et moins discriminante technologiquement, produit des valeurs plus régulières, donc souvent plus faciles à prédire à partir des *features* mécaniques; l'effet s'inverse toutefois là où le nombre d'observations NEDC est faible.

TAB. 4. Validation croisée (5 plis) par marché et par norme : RMSE $\pm$ écart-type inter-plis, MAE, et diagnostic biais-variance.

	Métrique	Model 2	XGBoost	MLP
Allemagne	RMSE _{WLTP}	7.27 $\pm$.23	5.73 $\pm$.23	13.06 $\pm$.44
	MAE _{WLTP}	4.36	2.94	8.88
	RMSE _{NEDC}	10.99 $\pm$.14	9.68 $\pm$.23	15.29 $\pm$.29
	MAE _{NEDC}	7.44	5.80	11.22
	Diag.	B	OL/OS	SA
Espagne	RMSE _{WLTP}	9.42 $\pm$.16	6.36 $\pm$.12	9.32 $\pm$.19
	MAE _{WLTP}	4.10	3.73	5.87
	RMSE _{NEDC}	7.36 $\pm$.39	6.57 $\pm$.29	9.58 $\pm$.57
	MAE _{NEDC}	3.11	2.46	5.10
	Diag.	B	B/OL	SA

B : bon compromis; OL/OS : overfitting léger / significatif; SA : sous-apprentissage.

2.3.4 Intervalles conformes (MAPIE)

Au-delà des métriques scalaires, l'auditabilité exige une borne d'incertitude. Les intervalles conformes (annexe A) sont directement actionnables : Model 2 produit des intervalles à 95 % de ± 14 g/km (Allemagne WLTP) à ± 22 g/km (Allemagne NEDC). Concrètement, une prédiction de 142 g/km peut s'accompagner d'une borne supérieure garantie à 95 %, exploitable dans un calcul d'exposition carbone conservateur, en conformité CSRD. Cette garantie de couverture est valable en distribution, sans hypothèse

sur la forme des résidus, ce qui la rend robuste à l'hétéroscédasticité de l'erreur selon les segments du parc.

Voies d'amélioration. Plusieurs pistes augmenteraient la précision ou l'utilisabilité : enrichissement des *features* par des données d'homologation externes (catalogues constructeurs, ADEME) après vérification de leur pouvoir prédictif via SHAP; optimisation bayésienne des hyperparamètres (Optuna, *Tree-structured Parzen Estimator*), plus efficace qu'une grille; et *stacking* de modèles aux erreurs structurellement décorréliées (LightGBM *leaf-wise*, XGBoost *level-wise*, MLP), un méta-modèle linéaire pondérant leurs prédictions *out-of-fold* pour éviter le surapprentissage du méta-modèle.

3 Vers un modèle international ?

Motivations. Le partenaire opère sur de nombreux marchés européens. Un modèle international agrégé offrirait trois avantages structurels par rapport à des modèles nationaux indépendants : (i) une taille d'entraînement bien supérieure, réduisant la variance des estimations pour les véhicules rares ou récents; (ii) des observations redondantes pour les modèles communs à plusieurs marchés (plateformes européennes partagées), renforçant la robustesse; (iii) une gouvernance et une maintenance simplifiées. Mais cette agrégation n'est légitime que si les distributions de covariables $P_c(X)$ sont suffisamment proches entre marchés : un modèle entraîné sur une distribution et appliqué sur une autre ne généralise pas de façon fiable. Nous testons donc cette faisabilité avant toute recommandation.

Classifieur de domaine. Suivant [8], nous entraînons un LightGBM multiclasse à prédire le *marché d'origine* d'un véhicule à partir de ses seules caractéristiques techniques (ENGINE_SIZE, ENGINE_WEIGHT, FUEL_TYPE, HORSEPOWER, CO2_WLTP). L'inclusion de la cible n'est pas problématique ici : on cherche à savoir non seulement si les véhicules diffèrent, mais aussi si la *relation* véhicule-émissions diffère entre marchés. Seuls les marchés disposant d'au moins 200 observations sont retenus. La courbe d'apprentissage (Fig. 7) ne montre pas d'overfitting significatif, et l'accuracy atteint ≈ 96 % : pour valider un modèle international, il aurait fallu une accuracy proche du hasard ($1/K$ pour K marchés).




FIG. 7. Classifieur de domaine (LightGBM multiclasse) : courbe d'apprentissage. Pas d'overfitting significatif.

La matrice de confusion (Fig. 8) confirme que les caractéristiques techniques permettent d'identifier le

marché d'origine avec une grande fiabilité, certains marchés se distinguant très fortement. Ce résultat peut surprendre, *a priori*, rien ne distingue le marché automobile global d'un pays d'un autre, mais l'échantillon reflète des directives commerciales et stratégiques d'octroi de prêts propres à chaque marché.




FIG. 8. Matrice de confusion du classifieur de domaine. Les marchés sont identifiés avec une grande fiabilité.

PCA et clustering des marchés. Pour comprendre cette discriminabilité, nous projetons les données par analyse en composantes principales (Fig. 9). Sur les trois premières composantes (qui expliquent $\approx 60\%$ de la variance), des clusters distincts par marché apparaissent nettement. L'ajustement est réalisé sur un échantillon stratifié d'environ 50 000 lignes par marché, et nous représentons les centroïdes de clusters obtenus par k -means ; un lissage par *mean-shift* a été testé pour atténuer le bruit mais dégradait la séparation spatiale. On remarque en particulier des clusters allongés et spatialement isolés pour certains marchés. Cette structure géométrique corrobore directement la performance du classifieur : les marchés occupent des régions distinctes de l'espace des *features*.




FIG. 9. Projection PCA (trois composantes, $\approx 60\%$ de variance) et centroïdes k -means par marché : des clusters distincts apparaissent.

Détection du covariate shift. Pour quantifier finement, pour chaque marché c , si $P_c(X) \neq P_{\text{global}}(X)$, nous entraînons un classifieur binaire LightGBM opposant les observations de c (label 0) à celles du jeu global (label

1). L'AUC mesure la séparabilité des deux distributions (proche de 0.5 : pas de shift détectable). Nous testons deux variantes : sur les *features* seules (X), et sur *features* + cible (X, Y), cette seconde détectant un éventuel *concept shift* (variation de $P(Y | X)$ entre marchés), plus grave qu'un simple décalage des caractéristiques. Les résultats (Table 5) montrent un **covariate shift marqué** (AUC de 0.82 à 0.98 selon le marché) mais $\text{AUC}(X) \approx \text{AUC}(X + Y)$: l'ajout de la cible n'augmente pas la séparabilité, donc **pas de concept shift**. La relation émissions-*features* est stable entre marchés ; seules les distributions de *features* diffèrent.

TAB. 5. AUC du classifieur binaire de domaine par marché (X : *features* seules ; $X + Y$: avec la cible CO2_WLTP).

Pays	AUC (X)	AUC (X + Y)	Interprétation
Allemagne	0.9841	0.9863	shift très fort
Portugal	0.9656	0.9737	shift très fort
France	0.8586	0.8579	shift fort
Espagne	0.8335	0.8327	shift fort
Italie	0.8201	0.8251	shift fort

Correction par reweighting et faisabilité. Le problème se réduisant à un covariate shift pur, il est corrigible par *importance reweighting* [18] : chaque observation du marché c reçoit un poids $w(x) = \hat{p}(x)/(1 - \hat{p}(x))$, où $\hat{p}(x)$ est la probabilité d'appartenance au jeu global donnée par le classifieur binaire (interprétation : rapport de vraisemblance p_{global}/p_c). Les poids sont clippés au 99^e centile et normalisés à moyenne 1, puis transmis via *sample_weight*, rapprochant la distribution d'entraînement de la distribution d'usage. Nos recommandations opérationnelles en découlent : modèle international directement applicable pour les marchés à faible AUC (< 0.70), avec un gain net en taille d'entraînement ; modèle national, ou international repondéré, pour les marchés à shift fort (> 0.80). Un point de vigilance : trois marchés concentrent $\approx 75\%$ des données, de sorte que le modèle global est de fait celui de ces marchés, et les performances sur un marché sous-représenté doivent être interprétées avec prudence, indépendamment de l'AUC.

4 Conclusion

Ce travail établit une méthodologie complète et *auditable* pour la prédiction de l'intensité carbone d'un portefeuille automobile réel, multi-marchés et hétérogène, un cadre éloigné des bases d'homologation propres de la littérature, et donc porteur de difficultés spécifiques.

Conclusions théoriques. Sur ce régime tabulaire, les arbres boostés dominent : LightGBM en périmètre de *features* restreint réalise le meilleur compromis biais-variance et surpasse systématiquement un MLP, conformément à la littérature et pour des raisons structurelles (biais spectral et invariance par rotation des réseaux denses, croissance *leaf-wise* de LightGBM mieux adaptée aux discontinuités des données). La prédiction conforme (MAPIE) fournit des intervalles statistiquement valides sous la seule hypothèse d'échangeabilité, sans recourir à la normalité ni à l'homoscédasticité des résidus.

Enfin, l'analyse de *dataset shift* établit un résultat net : un covariate shift inter-marchés fort mais sans concept shift, ce qui rend le transfert corrigible par repondération sans réapprendre la relation sous-jacente.

Conclusions pratiques. Pour le déploiement, Model 2 (LightGBM *light-scope*) est le candidat retenu : précis, robuste, et surtout auditable, le même modèle s'imposant sur tous les marchés. SHAP et les intervalles conformes fournissent les deux briques d'auditabilité exigées par le cadre réglementaire (CSRD). Le modèle international n'est pas directement transposable en l'état, mais une stratégie hybride (national / international repondéré selon l'AUC de shift) est actionnable.

Enjeux rencontrés et cheminement méthodologique. La démarche n'a pas été linéaire. La qualité dégradée et l'hétérogénéité des données ont imposé un pré-traitement et une imputation contrôlée en amont. Le choix de modèle a procédé par tâtonnement : une première approche locale (k -NN) a échoué en raison de la structure discrète, à frontières nettes, des données ; un premier modèle à arbres généraliste a souffert d'overfitting, et c'est l'inspection SHAP, utilisée comme outil de *diagnostic* et non de simple explication *a posteriori*, qui a révélé la nuisance des *features* redondantes et à haute cardinalité, motivant la réduction de périmètre décisive. Le besoin d'auditabilité, omniprésent, a guidé chaque arbitrage entre précision brute et exploitabilité. Le prolongement principal reste la prédiction de la distance annuelle parcourue, absente des données et nécessaire au calcul de l'empreinte totale. En plaçant l'auditabilité et la quantification de l'incertitude au même rang que la précision, la méthodologie vise à rester pertinente bien au-delà du cas d'application qui l'a motivée.

A Compléments théoriques

Nous supposons connus du lecteur les fondamentaux des modèles à arbres, du gradient boosting, du MLP et de la validation croisée à 5 plis, et nous limitons cette annexe aux points spécifiques à nos choix.

Gradient boosting. On apprend $f(x) = \sum_{t=1}^T \eta f_t(x)$, somme pondérée d'arbres CART, chaque f_t corrigeant les résidus de la somme précédente via un développement de Taylor au second ordre de la perte : avec g_i, h_i les gradient et hessienne, le poids optimal d'une feuille et le gain d'un split s'écrivent $w_j^* = -G_j/(H_j + \lambda)$ et $\text{Gain} = \frac{1}{2} [G_L^2/(H_L + \lambda) + G_R^2/(H_R + \lambda) - (G_L + G_R)^2/(H_L + H_R + \lambda)] - \gamma$, où G_j, H_j somment g_i, h_i sur la feuille.

LightGBM vs. XGBoost. Les deux partagent ce cadre, mais diffèrent sur quatre points décisifs. (1) *Histogram-based splitting* : LightGBM [6] discrétise chaque *feature* continue en $k \leq 255$ bins, ramenant le coût de recherche de split de $O(n \log n)$ à $O(k)$ par *feature*; une astuce de soustraction d'histogrammes ($\mathcal{H}_R = \mathcal{H}_{\text{parent}} - \mathcal{H}_L$) divise encore le coût par deux. (2) *GOSS (Gradient-based One-Side Sampling)* : on conserve intégralement les $a\%$ d'observations à fort $|g_i|$ (les plus informatives) et on sous-échantillonne une fraction b des observations à faible gradient, dont les gradients sont multipliés par $\frac{1-a}{b}$ pour garder un estimateur du gain non biaisé, on entraîne ainsi sur 20–40 % des données à précision quasi constante. (3) *EFB (Exclusive Feature Bundling)* : les *features* mutuellement exclusives (typiquement issues d'un *one-hot*) sont fusionnées par coloration de graphe en un seul *bundle*, réduisant la dimension effective de p à $p' \ll p$. (4) *Croissance leaf-wise* : c'est la différence la plus structurelle. XGBoost [2] croît *level-wise* (tous les nœuds d'un niveau développés avant le suivant, arbres symétriques), tandis que LightGBM croît *leaf-wise* (à chaque itération, on splitte la feuille de gain maximal, indépendamment de la profondeur). Pour un même budget de splits, LightGBM réduit la perte plus vite et concentre sa capacité sur les régions informatives, par exemple la discontinuité des véhicules électriques ($\text{CO}_2 \approx 0$), identifiée et approfondie immédiatement, là où XGBoost dilue une partie du budget sur des régions à faible résidu. Le risque de surapprentissage de la stratégie *leaf-wise* est contrôlé par `num_leaves` et `max_depth`.

Optimiseur Adam. Pour le MLP, Adam [7] adapte le pas par poids via les moments d'ordre 1 et 2 du gradient :

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t, \quad v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2, \quad (4)$$

$$w \leftarrow w - \frac{\eta}{\sqrt{\hat{v}_t} + \epsilon} \hat{m}_t, \quad \hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t}. \quad (5)$$

Plus robuste au bruit et plus rapide que SGD, sans *tuning* préalable des *features*.

Intervalles conformes (MAPIE). La prédiction conforme [21, 19, 3] ne suppose que l'*échangeabilité* (plus faible que l'i.i.d.), ni normalité ni homoscélasticité des résidus. Sur un ensemble de calibration $\mathcal{D}_{\text{cal}}$ disjoint de l'entraînement, on calcule les scores de non-conformité $s_i = |y_i - \hat{f}(x_i)|$, puis le quantile empirique $\hat{q}_{1-\alpha}$; l'intervalle pour un nouveau x est $\hat{C}_\alpha(x) = [\hat{f}(x) \pm \hat{q}_{1-\alpha}]$. Pour ne pas sacrifier un ensemble fixe et réduire la variance, nous intégrons MAPIE dans chaque pli de la 5-CV (ajustement 80 % / calibration 20 %, `cv="prefit"`), pour $1 - \alpha \in \{80, 90, 95\}\%$, puis agrégeons. Interprétation : un intervalle à 95 % de ± 14 g/km signifie qu'au moins 95 véhicules sur 100, tirés de la même population, ont leur CO_2 réel dans l'intervalle prédit.

B Heatmaps de cohérence (Allemagne, WLTP)

Les heatmaps ci-dessous représentent l'intensité de CO_2 dans un plan de *features* (p. ex. `ENGINE_WEIGHT` × `ENGINE_SIZE`). Pour chaque modèle, on présente trois plans ; chaque vignette juxtapose la distribution *avant* et *après* prédiction, avec l'échelle de couleur associée. Elles servent de contrôle heuristique : un modèle fidèle ne doit ni surcharger ni sous-charger de région, et doit restituer la nullité des véhicules électriques.




Fig. 10. Model 1 (full-scope), Allemagne, cible WLTP : heatmaps de cohérence CO₂ sur trois plans de *features*. Chaque vignette compare la distribution *avant* (gauche) et *après* (droite) prédiction.




Fig. 11. Model 2 (light-scope), Allemagne, cible WLTP : heatmaps de cohérence CO₂ sur trois plans de *features* (*avant* vs. *après* prédiction). La géométrie initiale est fidèlement restituée.




FIG. 12. XGBoost (light-scope), Allemagne, cible WLTP : heatmaps de cohérence CO₂ sur trois plans de *features* (*avant* vs. *après* prédiction).




FIG. 13. MLP, Allemagne, cible WLTP : heatmaps de cohérence CO₂ sur trois plans de *features* (*avant* vs. *après* prédiction). Le sous-apprentissage se traduit par des régions lissées.

Références

- [1] Akinosho, T. D., Oyedele, L. O., & Davison, B. (2024). *Application of Machine Learning to Predict CO₂ Emissions in Light-Duty Vehicles*. *Sensors*, 24(24), 8219.
- [2] Chen, T., & Guestrin, C. (2016). *XGBoost : A Scalable Tree Boosting System*. *Proc. 22nd ACM SIGKDD*, 785–794.
- [3] Cordier, T., Blot, V., Lacombe, L., Morzadec, T., Capitaine, A., & Brunel, N. (2023). *Flexible and Systematic Uncertainty Estimation with Conformal Prediction via the MAPIE library*. *COPA*, PMLR.
- [4] Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). *Why do tree-based models still outperform deep learning on typical tabular data ?* *NeurIPS* 35, 507–520.
- [5] Gurcan, F. (2024). *Forecasting CO₂ emissions of fuel vehicles using ensemble learning, machine learning, and deep learning models*. *PeerJ Computer Science*, 10, e2234.
- [6] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). *LightGBM : A Highly Efficient Gradient Boosting Decision Tree*. *NeurIPS* 30.
- [7] Kingma, D. P., & Ba, J. (2015). *Adam : A Method for Stochastic Optimization*. *ICLR 2015*. arXiv :1412.6980.
- [8] Lopez-Paz, D., & Oquab, M. (2017). *Revisiting Classifier Two-Sample Tests*. *ICLR 2017*. arXiv :1610.06545.
- [9] Lundberg, S. M., & Lee, S.-I. (2017). *A Unified Approach to Interpreting Model Predictions*. *NeurIPS* 30.
- [10] Lundberg, S. M., Erion, G., Chen, H., et al. (2020). *From local explanations to global understanding with explainable AI for trees*. *Nature Machine Intelligence*, 2, 56–67.
- [11] Muraru, M. M., Simó, Z., & Iantovics, L. B. (2025). *Study on State-of-the-Art ML Algorithms Efficiency for CO₂ Emissions Prediction in Fleet Management Optimization*. *LNNS*, vol. 1249, Springer.
- [12] Nader, Y., Sixt, L., & Landgraf, T. (2022). *DNNR : Differential Nearest Neighbors Regression*. arXiv :2205.08434.
- [13] Natarajan, Y., Wadhwa, G., Sri Preethaa, K. R., & Paul, A. (2023). *Forecasting Carbon Dioxide Emissions of Light-Duty Vehicles with Different Machine Learning Algorithms*. *Electronics*, 12(10), 2288.
- [14] Ng, A. Y. (2004). *Feature selection, L1 vs. L2 regularization, and rotational invariance*. *ICML 2004*, art. 78.
- [15] Rahaman, N., Baratin, A., Arpit, D., et al. (2019). *On the Spectral Bias of Neural Networks*. *ICML 2019*, PMLR 97, 5301–5310.
- [16] Shapley, L. S. (1953). *A Value for n-Person Games*. *Contributions to the Theory of Games*, vol. 2, 307–317. Princeton Univ. Press.
- [17] Shwartz-Ziv, R., & Armon, A. (2022). *Tabular Data : Deep Learning is Not All You Need*. *Information Fusion*, 81, 84–90.
- [18] Sugiyama, M., Krauledat, M., & Müller, K.-R. (2007). *Covariate Shift Adaptation by Importance Weighted Cross Validation*. *JMLR*, 8(35), 985–1005.
- [19] Taquet, V., Blot, V., Morzadec, T., Lacombe, L., & Brunel, N. (2022). *MAPIE : an open-source library for distribution-free uncertainty quantification*. arXiv :2207.12274.
- [20] Tena-Gago, D., Serna, A., & Lozano-Diez, A. (2023). *Machine-Learning-Based Carbon Dioxide Concentration Prediction for Hybrid Vehicles*. *Sensors*, 23(3), 1563.
- [21] Vovk, V., Gammerman, A., & Shafer, G. (2005). *Algorithmic Learning in a Random World*. Springer.