

Conflits, technologies et sécurité mondiale

De l'usage des deepfakes dans la guerre informationnelle moderne

Arthur Filippi Salvador Levy Pierre Blusseau-Bourcier

École Polytechnique

Travail réalisé pour le CIEDS (Centre Interdisciplinaire d'Études pour la Défense et la Sécurité),
dans le cadre de l'*Entente Cordiale Day Challenge*

{arthur.filippi, salvador.levy, pierre.blusseau-bourcier}@polytechnique.edu

Résumé

Les deepfakes, contenus audio ou visuels synthétiques générés par des modèles d'intelligence artificielle, sont devenus l'une des armes les plus puissantes de la guerre informationnelle contemporaine. Ce rapport dresse d'abord un état de l'art *géostratégique* de leur usage, à travers une série de conflits récents (Russie–Ukraine, Israël–Hamas, Inde–Pakistan, Syrie, Afrique subsaharienne), puis un état de l'art *technique* de leur génération (GANs, modèles de diffusion, synthèse vocale), de leur détection et des dispositifs de lutte existants. Sur cette base, il propose un ensemble de solutions articulées autour de trois leviers, *détecter* (CAPTCHA participatifs, traçabilité par blockchain), *sanctionner* (cadre de non-prolifération, licences d'IA génératives) et *éduquer* (éducation aux médias, apprentissage actif), avant d'examiner la bascule vers un usage *offensif* des deepfakes par les États. La thèse centrale est que la lutte doit devenir un effort systémique, permanent et adaptatif, combinant innovation technologique, participation citoyenne et coopération internationale.

1 Introduction

Les deepfakes désignent des contenus audio ou visuels synthétiques générés par des modèles d'intelligence artificielle capables d'imiter une voix, un visage ou un mouvement de manière indiscernable du modèle d'origine. S'appuyant sur des réseaux de neurones, les deepfakes constituent aujourd'hui l'une des techniques de manipulation de l'information les plus puissantes et les plus répandues. Leur diffusion massive, facilitée par les réseaux sociaux et la prolifération d'outils accessibles au grand public, soulève des enjeux majeurs pour la sécurité internationale, la confiance publique et la stabilité géopolitique, et est paradigmatique d'un lien accru entre la technologie et les conflits modernes.

Après avoir dressé un état de l'art de l'usage actuel des deepfakes dans la guerre informationnelle, nous formulerons plusieurs recommandations, applicables à différentes échelles, pour répondre efficacement à cette menace croissante. Notre rapport cherchera donc à apporter une réponse à la question suivante : comment les États et les institutions doivent-ils appréhender l'usage des deepfakes dans un cadre de guerre informationnelle et d'influences constante ?

2 État de l'art de l'usage des deepfakes

2.1 État de l'art géostratégique

Les deepfakes sont aujourd'hui un outil stratégique mobilisé dans de nombreux conflits. Leur usage répond le plus souvent à deux intentions majeures : influencer l'opinion publique et déstabiliser l'adversaire stratégiquement. Pour comprendre les particularités de l'usage des deepfakes comme « arme de guerre », étudions-en quelques cas récents.

2.1.1 Russie – Ukraine

Le conflit russo-ukrainien représente l'un des terrains les plus documentés d'usage de deepfakes (Singh, 2025). En mars 2022, un deepfake de Volodymyr Zelensky a circulé, qui l'imitait appelant les soldats ukrainiens à déposer les armes. Une version symétrique a visé Vladimir Poutine, annonçant une fausse mobilisation générale. Si la qualité de ces deepfakes était assez sommaire (on peut très facilement les identifier comme tels), leur objectif psychologique était clair : introduire un doute, fracturer la cohésion mentale, tester la porosité de l'information (Barthélemy, 2025). Leur diffusion rapide souligne l'importance stratégique (Majchrzak, 2023) des plateformes numériques dans les opérations d'influence hybrides, notamment Telegram et X (anciennement Twitter) qui ont abondé de tels exemples, et que les services de renseignement infiltrèrent souvent pour déterminer comment les utiliser comme vecteurs de propagation de fausses informations.

2.1.2 Israël – Hamas

Dans le conflit Israël-Hamas, des deepfakes d'enfants blessés ou de civils en situation de détresse ont été massivement diffusés pour polariser l'opinion publique (Thomson, 2023 ; Kazic, 2024). Des montages visuels, certains assez grossiers, d'autres beaucoup moins faciles à identifier, ont circulé plus rapidement que les démentis officiels. Ces contenus s'inscrivent dans une stratégie visant à maximiser l'impact émotionnel afin de mobiliser ou radicaliser le public, amplifier l'indignation ou la colère, et saturer l'espace médiatique. Notons que la cible principale était bien l'opinion publique internationale, plus que l'opinion publique locale, afin de s'attirer la sympathie d'alliés potentiels. Notons également qu'il s'agit d'un outil qui s'intègre parmi une batterie d'autres dans le cadre d'une stratégie de communication globale : du côté israélien, cela rentre dans la *hasbara*, qui inclut tous les usages de

stratégies de communication dans le cadre de la diplomatie publique.

2.1.3 Inde – Pakistan

Le sous-continent indien connaît une intense activité de désinformation. Dans ce contexte, les deepfakes ont été employés pour simuler des soldats pakistanais reconnaissant une défaite, ou pour imiter des responsables religieux indiens appelant à la vengeance (Singh, 2025). Ces contenus sont amplifiés par les tensions communautaires et les chaînes de messagerie chiffrée, où ils circulent sans contrôle. Leur efficacité repose sur leur capacité à exploiter les fractures identitaires, et ils renforcent les risques d'escalade. Ils introduisent également une incertitude qui complexifie l'analyse stratégique (Kashif-Janjua, 2025) : un message attribué à un acteur officiel peut désormais être perçu comme potentiellement faux, ce qui fragilise la confiance institutionnelle.

2.1.4 Syrie

À la chute du régime de Bachar al-Assad, un deepfake du dirigeant annonçait son refus de capituler et appelait les forces loyalistes à continuer la lutte. Diffusé dans des zones où l'information officielle circulait mal, ce deepfake a créé une confusion importante (Kazic, 2024), illustrant la vulnérabilité des populations dans les contextes de fragmentation médiatique. La stratégie ici est caractéristique de la guerre psychologique visant à perturber la chaîne de commandement (Byman et al., 2023). Une annonce falsifiée de reddition ou, au contraire, de résistance acharnée peut modifier les comportements tactiques sur le terrain. Ce cas illustre le danger spécifique des deepfakes dans les environnements de guerre asymétrique, où les communications sont sporadiques et où un message synthétique bien placé peut avoir un effet disproportionné.

2.1.5 Afrique subsaharienne

Dans plusieurs régions d'Afrique subsaharienne, notamment en Éthiopie, au Soudan du Sud et dans certaines zones sahéliennes, des deepfakes vocaux imitant des chefs communautaires ont encouragé des représailles ou annoncé de fausses attaques imminentes (Breland, 2019). Dans des sociétés où les médias traditionnels sont faibles et où la radio communautaire joue un rôle central, la propagation de deepfakes audio constitue une menace grave (Johnson, 2019). Ces deepfakes se combinent souvent à des rumeurs préexistantes, produisant un effet de résonance informationnelle. Les violences interethniques peuvent ainsi être déclenchées ou amplifiées par un simple message vocal falsifié. L'impact dépasse donc la désinformation : il s'agit d'un outil de manipulation à la capacité potentiellement létale.

2.1.6 Conclusions

L'analyse de l'ensemble de ces cas révèle une constante : l'efficacité des deepfakes ne repose pas uniquement sur leur réalisme, mais surtout sur leur capacité à infiltrer des

environnements déjà instables, émotionnels ou polarisés. Ils sont avant tout des instruments de déstabilisation, utilisés pour perturber la perception, affaiblir l'autorité, fragmenter les sociétés et modifier les équilibres stratégiques. Ils sont également naturellement utilisés en majorité sur les populations civiles, afin d'influencer l'opinion publique.

Ajoutons que lors de la rédaction-même de ce rapport, le 16 décembre 2025, un deepfake évoquant un coup d'État en France a été massivement relayé sur les réseaux sociaux (12M de vues), notamment Facebook. Le retentissement de ce deepfake, mettant en scène une journaliste sur les quais de Seine, a été tel qu'un président africain (dont l'identité n'a pas été révélée) a contacté Emmanuel Macron. Apparemment réalisé sans intention de nuire, ce deepfake souligne néanmoins la facilité d'escalade dans de telles situations.

3 État de l'art technique

3.1 Génération des deepfakes

La génération de deepfakes s'appuie sur plusieurs familles de modèles (Owasp, 2023) :

- Les **GANs** (*generative adversarial networks*) : un générateur, fondé sur l'intelligence artificielle, produit des images réalistes qu'il soumet à un discriminateur (également une IA) qui tente de les distinguer d'images réelles, créant une compétition qui améliore progressivement leur qualité, jusqu'à ce que le discriminateur juge l'image satisfaisante (Bonnet et al., 2025) ;
- Les **modèles de diffusion** (Bonnet et al., 2025) : ils génèrent des images en partant d'un « bruit », c'est-à-dire des pixels aléatoires, et en raffinant progressivement la composition de l'image à partir d'une base de données d'entraînement ;
- Les **modèles vocaux** (Bendiab et al., 2025) : à partir de modèles de langage et de l'apprentissage de signatures spectrales, ils permettent de générer un discours et des voix particulières.

Ces techniques sont désormais accessibles au grand public, ce qui abaisse considérablement les barrières à l'entrée pour des acteurs non étatiques (comme les groupes terroristes ou les milices locales) : des plateformes telles que DeepFaceLab, FaceSwap ou des services automatisés comme HeyGen ou DeepfakeWeb permettent de créer des deepfakes en quelques secondes.

3.2 Détection des deepfakes

La détection des deepfakes repose sur deux approches principales. La première est algorithmique (Cinar, 2023) : des modèles supervisés apprennent à identifier des anomalies visuelles (expressions faciales, ombres, formes), audio (déphasage spectral, absence de bruit de fond cohérent) ou multimodales (désynchronisation labiale) (Abdulhamied et al., 2025). La seconde est forensique : vérification des métadonnées, analyse de la traçabilité via des signatures numériques et la filiation des fichiers.

Cependant, l'équilibre entre génération et détection demeure instable : les modèles génératifs progressent plus




FIG. 1 : Fonctionnement général d'un GAN (*generative adversarial network*).

vite que les détecteurs. Comme dans toute situation de compétition adverse, une approche purement algorithmique est vouée à l'échec sur le long terme, puisqu'elle alimente les réseaux mêmes qu'elle tente de combattre.

3.3 Lutte contre les deepfakes

Les stratégies actuelles de lutte contre les deepfakes se répartissent en trois axes principaux : la régulation, la détection et l'éducation du public.

Sur le **plan juridique**, plusieurs États ont adopté des cadres visant à responsabiliser les plateformes, à imposer des obligations de retrait rapide ou à sanctionner la manipulation malveillante de l'information. Les États-Unis, par exemple, ont introduit des lois électorales régionales interdisant la diffusion de deepfakes politiques à proximité d'un scrutin, tandis que l'Union européenne renforce avec le DSA (*Digital Services Act*) les normes de traçabilité et de signalement. En France, un cadre juridique existe depuis 2024 : les peines vont « seulement » jusqu'à 45 000 € d'amende et 2 ans de prison pour la diffusion de deepfakes d'une personne non consentante et non labellisée comme générée par IA, et il s'agit de 75 000 € d'amende et 3 ans de prison pour du contenu à caractère pornographique (Gouvernement français, 2024). La jurisprudence en matière de création ou de diffusion de deepfakes demeure, quant à elle, encore en construction. Ainsi, en janvier 2026, le gouvernement français a pour la première fois saisi le procureur de la République afin de lancer une enquête contre le réseau social X à cause de son IA *Grok*, massivement utilisée par les internautes pour dénuder des femmes, parfois mineures. Malheureusement, seuls les utilisateurs encourent concrètement les peines énoncées plus haut, et la principale réaction d'Elon Musk fut de rendre payant l'outil de génération et non de songer à une quelconque modération de celui-ci (Deromas-Lebocq, 2026).

Sur le **plan technique**, les plateformes expérimentent des systèmes de *watermarking* ou de marquage numérique visant à distinguer les contenus générés par IA, complétés par des outils de détection automatisée basés sur l'analyse forensique (incohérences et défauts d'image).

Sur le **plan éducatif**, certaines campagnes de sensibilisation cherchent à apprendre aux citoyens à repérer les signes de manipulation visuelle, à vérifier les sources et à adopter une posture critique face aux images virales : mentionnons par exemple le podcast « Les Voies de l'IA » proposé par l'Observatoire de l'IA, ou les initiatives de KlickSafe à l'échelle européenne, telles que le webinar « Deep Fake, Deep Impact » le 01/10/2025 et la mise à disposition de matériel pédagogique contre la cyber-manipulation.

Cependant, ces approches restent partielles et hétérogènes. La régulation avance lentement et demeure dépendante d'un consensus inter-étatique, alors que la désinformation circule globalement. Les dispositifs techniques, bien qu'utiles, sont fragiles face à l'amélioration rapide des modèles génératifs. Quant aux initiatives éducatives, elles peinent à toucher les publics les plus vulnérables ou les zones de conflit, où les deepfakes sont précisément les plus déstabilisateurs. La réalité géopolitique actuelle impose donc une stratégie plus intégrée, capable d'articuler simultanément innovation technologique, participation citoyenne, coopération internationale et anticipation des nouvelles capacités offensives offertes par l'IA. Autrement dit, la lutte contre les deepfakes doit devenir un effort systémique, permanent et adaptatif, plutôt qu'un ensemble d'initiatives isolées et réactives.

4 Solutions envisagées

4.1 Détecter

4.1.1 Des CAPTCHA pour renforcer la détection et la résilience

Une solution purement technique consisterait à transformer le concept classique du CAPTCHA en un outil d'entraînement simultané pour les humains et les modèles de détection. Au lieu d'identifier des feux rouges ou des passages piétons, l'utilisateur serait confronté à des éléments visuels ou audio intégrant des deepfakes. Le système poursuit un double objectif :

1. renforcer la capacité humaine à reconnaître les deepfakes, par exposition répétée à des deepfakes utilisés dans des situations réelles ;
2. alimenter les modèles de détection, grâce à la participation massive et distribuée des utilisateurs.

Cette approche est hautement extensible : des millions d'internautes peuvent participer sans effort supplémentaire, comme ils le font déjà pour les CAPTCHA traditionnels. Elle touche de plus toutes les catégories d'âge, y compris les adultes et personnes âgées, contrairement aux campagnes d'éducation numérique qui ne s'adressent qu'aux jeunes. Ensuite, elle fournit une amélioration continue des modèles grâce à un flux constant d'annotations : on ne se contente plus de baser la détection sur telle ou telle anomalie récurrente, mais on capitalise sur la capacité humaine à discerner les contenus réels des artificiels. Elle permet également de renforcer la résilience cognitive des populations face aux manipulations visuelles, anime un mécanisme de surveillance collective et s'intègre




FIG. 2 : Exemple de CAPTCHA anti-deepfake que l'on pourrait proposer.

facilement dans les plateformes existantes. Enfin, elle constitue une stratégie à faible coût, reposant sur des infrastructures déjà déployées.

Bien sûr, cette solution en l'état n'est pas exempte de limites : avant toute chose, elle repose sur la confiance en la capacité humaine à discriminer les contenus factices, si on surestime cette capacité, on s'expose à dégrader nos modèles de détection algorithmique, que l'on alimente avec les réponses des internautes. Pour pallier ce risque, il convient de faire précéder le déploiement de cette solution d'une phase de test, pour estimer la capacité humaine de détection. On peut également envisager d'adopter un mode « pédagogique » qui propose après le CAPTCHA un bref retour en soulignant les détails qui auraient dû alerter l'utilisateur. Une autre limite concerne l'efficacité géographique de la solution : les populations les plus exposées aux deepfakes sont aussi les moins bien informées, et leur usage d'internet est certainement moindre que dans les pays développés. Pour répondre à ce problème, on pourrait envisager de cloner les CAPTCHA sur d'autres vecteurs informationnels : sous forme de jeux dans les journaux, à la radio, ou encore à la télévision. Cela suppose bien sûr la participation des autorités locales, mais dans la mesure où elles sont souvent menacées par l'abondance de deepfakes, ce point ne semble pas être le principal facteur limitant.

4.1.2 La blockchain pour améliorer la traçabilité des contenus

Une solution possible afin de lutter contre les deepfakes serait d'utiliser une technologie récente mais fiable et efficace : la blockchain (Rashid, 2021). Il s'agit d'une base de données permettant à plusieurs individus de partager et stocker des informations, et ce de manière anonyme, sécurisée et sans passer par des plateformes intermédiaires. L'intérêt est donc que lorsqu'une information est ajoutée

ou modifiée, tout est marqué dans la blockchain à travers un *hash*, c'est-à-dire un identifiant numérique. Il est donc possible de retracer la vie des données. Concrètement, on y stocke des preuves horodatées (transactions, certificats, empreintes de fichiers) : chaque entrée contient un identifiant unique, la signature numérique de l'émetteur et une date, ce qui permet de vérifier l'origine et l'intégrité d'un fichier sans passer par un intermédiaire de confiance. La force de la blockchain vient donc de sa décentralisation, de la cryptographie et de la transparence (Freeman, 2025).

Par conséquent, dans le cas des deepfakes, une fois la vidéo originale enregistrée sur la blockchain, on pourrait savoir, en regardant une version modifiée de l'originale, qu'il s'agit d'un montage. Concrètement, pour mettre cela en place, il faudrait créer une blockchain commune à tous les médias, les journalistes, les politiques, les influenceurs et plus globalement toutes les personnes susceptibles de publier des vidéos sur des plateformes d'information. Dès lors, quand un journaliste prendra une vidéo et l'enregistrera sur la blockchain, un *hash* sera attribué à cette vidéo. Ainsi, lorsqu'un individu malveillant souhaitera publier un montage de cette vidéo, il suffira de regarder le *hash* de celle-ci, puis de vérifier dans la base de données de la blockchain si le *hash* correspond à celui d'une vidéo enregistrée par une entité vérifiée. Si le *hash* ne correspond à aucune autre vidéo, cela veut dire qu'il ne s'agit pas d'une vidéo officielle, et donc, si elle met en scène des personnalités publiques, qu'elle est probablement truquée.

Ainsi, par une simple vérification, il serait possible de savoir si une vidéo est officielle ou non. Cette vérification pourrait être effectuée de différentes manières, plus ou moins efficaces. Cela peut être fait par un partenariat avec les plateformes (Patil, 2021) : il serait du rôle de celles-ci d'effectuer cette vérification, auquel cas elle pourrait spécifier directement auprès des utilisateurs qu'il s'agit d'un montage. Sinon, cela peut être fait par les utilisateurs eux-mêmes, grâce à un logiciel dédié, créé par le gouvernement. Cette dernière méthode serait forcément moins efficace car elle demanderait à l'utilisateur de faire la vérification, et donc d'avoir installé le logiciel au préalable et de savoir comment l'utiliser. On peut ainsi imaginer une coopération internationale pour créer une blockchain commune à différents pays, qui pourrait couvrir une grande partie des contenus publiés.

Néanmoins, cette solution présente des limites. D'abord, si une entité souhaite propager une fausse vidéo, n'en reprenant aucune autre déjà produite, cela ne peut pas être détecté. Typiquement, des deepfakes de civils blessés dans le conflit israélo-palestinien ne sont pas détectables comme un montage par la blockchain, car il n'existe aucune information sur la vidéo originale ; au mieux, nous saurons qu'elle n'a pas été publiée par des médias officiels. Aussi, le fait de mettre en place une blockchain commune créée par un gouvernement peut amener certains médias à redouter la censure ou la manipulation par les instances étatiques, qui refuseront donc de rejoindre la blockchain (Lokhande, 2024).

4.2 Sanctionner

Il convient enfin de se pencher sur ce que la loi peut offrir comme garanties pour contrer des attaques aux recours

complexes usant du droit, dans un contexte plus global que les accords qui existent déjà ponctuellement dans le monde.

4.2.1 Endiguer la prolifération des deepfakes

Une première solution contre la création de contenu à teneur mensongère serait d'adopter un cadre international de non-prolifération des deepfakes, à l'instar des Traités d'Oslo (2008) et d'Ottawa (1997), interdisant la production, la détention, le transfert et l'usage respectivement d'armes à sous-munitions et de mines anti-personnel. En effet, la signature de ces traités par un pays lui impose entre autres la déclaration de ses stocks auprès du secrétariat de la Convention de Genève et leur destruction dans un délai accordé (Nations Unies, 2026). Malheureusement, ces traités ne sont ratifiés que par les pays volontaires et il est tout à fait possible pour ceux-ci de s'en retirer. Le champ de bataille ukrainien en est le parfait exemple de violation de ces règles puisque l'utilisation par les deux camps a bel et bien été signalée dès 2022. Ce cadre, quoiqu'éthiquement correct, pourrait donc s'avérer être plus un vecteur de déséquilibre entre puissances possédant la capacité d'utiliser les deepfakes qu'autre chose.

Une autre entrave envisageable serait celle de la limitation des capacités de calcul des IA génératives suivant leurs usages. On peut imaginer la création d'une catégorisation des IA, avec pour chacune une « licence » nécessaire à son emploi, dont le numéro serait inséré en filigrane dans les métadonnées des images générées. Un exemple de catégories lettrées serait :

- **Catégorie A** : IA génératives professionnelles et à but culturel, nécessitant une demande d'autorisation gouvernementale ou d'un organisme international, accompagnée du projet détaillé du film, de l'audio, de l'image, etc. Non limitées, car elles permettent certaines prouesses techniques notamment dans le cinéma et la musique.
- **Catégorie B** : IA génératives professionnelles et à fins de divertissement, aux capacités légèrement réduites et soumises à un contrôle d'identité et un permis d'utilisation, permettant notamment aux créateurs de contenus numériques de poursuivre leur activité. Le permis pourrait être retiré en cas de création et de diffusion de deepfakes.
- **Catégorie C** : IA génératives à usage personnel, aux capacités nettement réduites et soumises à un contrôle d'identité et un certificat d'aptitude à l'utilisation, permettant également de retracer la provenance d'éventuels deepfakes et ainsi d'appliquer des sanctions si besoin.

Néanmoins, la question éthique se pose : porte-t-on atteinte à la liberté d'expression ? Dans quelle mesure cela est-il acceptable ? Plusieurs enquêtes ont déjà été menées sur l'opinion publique à propos des usages de l'IA, leur contrôle par les gouvernements et la perception de leur avenir dans des domaines tels que l'amélioration des conditions de travail, le divertissement, la santé ou encore la politique. En particulier, il est intéressant de distinguer les utilisateurs « experts » de l'IA (ceux qui étudient

et l'utilisent à des fins professionnelles) du reste de la population. Force est de constater qu'il y a de grandes disparités de perception entre experts de l'IA et population générale quant aux bénéfices sociaux de l'IA : aux États-Unis, les experts de l'IA sont bien plus enthousiastes que les autres (McClain et al., 2025). Néanmoins, dans les domaines qui nous intéressent comme les élections, les deux catégories s'accordent sur le fait que l'usage des IA n'améliore et n'améliorera pas le processus électoral. Pour ce qui est de la régulation, toujours aux États-Unis, les résultats sont similaires entre experts et non-experts : respectivement 55 et 57 % de ces catégories désirent plus de contrôle du gouvernement, et tous s'inquiètent davantage du laxisme gouvernemental que d'un contrôle trop sévère.

4.2.2 Entraver la diffusion des deepfakes

Dans un second temps, on peut envisager là encore de créer un cadre international de non-diffusion des deepfakes. Mais on peut songer aussi à des directives nationales, qui criminaliseraient le relai de fausse information, à dessein ou non. Ce levier serait en fait double : d'une part l'on dissuaderait de diffuser de l'information non vérifiée et donc potentiellement fausse ; d'autre part l'on inciterait chacun à vérifier la source et la véracité du contenu qu'il s'apprête à partager. Cela impliquerait cependant un cadre juridique très précis afin de définir le type de contenu à bannir, et il faudra être extrêmement précautionneux afin de ne pas tomber dans l'écueil d'une censure abusive et autoritaire.

5 Éduquer

5.1 Améliorer l'éducation aux médias et à l'information

Il s'agirait, à ce dernier niveau, de sensibiliser et d'éduquer la population aux implications du visionnage de contenu deepfake. En réalité, ce recours est également le summum de la protection : si plus personne, au niveau individuel, ne s'égare quant à la véracité des informations qu'il reçoit, l'on peut en déduire que seuls les individus mal intentionnés seraient susceptibles de les diffuser, et donc les sanctions légales seraient mieux ciblées et bien moins discutables. Mais comment atteindre cet idéal ? On peut envisager d'intégrer dans le cadre de l'éducation aux médias et à l'information (EMI) une composante deepfakes dès le plus jeune âge, typiquement dès l'école primaire. Cette EMI académique devra en outre être complétée de campagnes de sensibilisation publiques telles celles qui ont émergé à partir de 1980 pour lutter contre le SIDA : affichages, slogans publicitaires, publications, etc.

5.2 Un apprentissage actif et régulier

Enfin, il faut mettre l'utilisateur lui-même dans la boucle afin de le rendre actif dans cette démarche de lutte cognitive : par exemple, contraindre périodiquement l'accès d'un réseau social par un questionnaire de « bonnes conduites » à l'ouverture, que l'on recommence tant que l'on n'obtient pas un certain score et qui se réinitialise chaque semaine ou chaque mois avec des questions de difficulté croissante.

En termes de score, on peut également envisager de créer une quantification du niveau de fiabilité des internautes

et faire apparaître ce score à chaque publication, afin que chacun puisse accorder le crédit qu'il souhaite à tel ou tel post. Un système type étoiles, comme sur les sites de commerce en ligne, de logements ou de restaurants, serait une application des plus efficaces : l'effet porterait à la fois sur l'utilisateur, qui doit prendre garde à ce qu'il publie, et sur le consommateur de contenu, qui portera une attention accrue à la notation du profil en question. Une autre solution serait un formulaire de justification de republication, à l'instar de ceux existant pour les signalements de contenu illicite : celui-ci forcerait les gens à réfléchir au sens de leurs pratiques numériques et attirerait leur attention sur certains points de l'image et/ou de l'audio, avec des questions telles que « trouvez-vous le regard de la personne naturel ? », « les mouvements sont-ils cohérents ? », etc.

D'autres réponses à cette problématique se trouvent du côté de la psychologie sociale. En effet, derrière la diffusion de toute rumeur il existe des mécanismes humains qu'il faut parvenir à identifier clairement afin de les combattre. Selon une étude, quelques-uns des principaux facteurs du succès des rumeurs et de leur propagation rapide sont le manque d'esprit critique et de discernement, corrélés à une littératie et une culture générale peu développées, ainsi que le biais de confirmation (Beauvais, 2022). Mener de grandes campagnes d'information à propos des sujets sensibles du moment peut avoir de l'effet chez certains en augmentant leur compréhension... mais pas chez d'autres, notamment à cause du biais de confirmation. Une autre approche proposée serait d'« inverser » l'algorithme des médias de diffusion. En effet, les réseaux sociaux ont tendance à promouvoir le contenu sur la base de celui qui a déjà été visionné par le consommateur, cernant ainsi les émotions ressenties par lui. En identifiant justement le potentiel émotionnel et sensationnel d'une information, l'on pourrait parvenir à ralentir sa propagation de manière algorithmique, ce qui permettrait à des organismes de *fact-checking* d'avoir suffisamment de temps pour trancher sur sa véracité. Il faudra néanmoins veiller à ce que l'information circule à une vitesse raisonnable afin de se garder d'éventuelles critiques de type *gatekeeping*. Les critères que nous proposons pour quantifier ce potentiel émotionnel sont les suivants : récence des faits, niveau d'intérêt de la population et niveau de controverse associé.

6 Vers un usage offensif des deepfakes ?

6.1 Une tendance déjà amorcée

Comme vu précédemment, les deepfakes peuvent s'avérer très efficaces lors d'opérations d'influence et de manipulation. C'est pourquoi certains pays occidentaux envisagent leur utilisation. Ainsi, le *United States Special Operations Command* (SOCOM), centre de commandement des forces spéciales américaines, a déjà commencé à travailler sur une utilisation des deepfakes. Les membres de l'état-major abordent le sujet, accompagnés de psychologues et d'experts des réseaux afin de mettre en place des systèmes d'influence. Ils disent avoir développé des outils qui leur permettent d'évaluer le domaine des réseaux, d'analyser les tendances et les divergences d'opinions afin d'influencer potentiellement

cet environnement avec leurs propres outils.

De ce fait, dans un document non classifié (USSOCOM, 2023), le SOCOM annonce avoir lancé des recherches qui permettraient de « fournir une nouvelle génération de technologie de type deepfake ou similaire afin de générer des messages et des opérations d'influence via des canaux non traditionnels dans des environnements pertinents contre des pairs ou quasi-pairs ». Ici, la volonté d'utiliser les deepfakes de manière offensive est donc clairement assumée (Rempfer, 2019). En décembre 2024, *The Intercept* a rapporté que le SOCOM avait convaincu X (Fang, 2022 ; Biddle, 2023), en violation de ses propres règles internes, d'autoriser un réseau de faux comptes qui diffusaient de fausses informations, notamment une selon laquelle le gouvernement iranien volait les organes de civils afghans. Bien que cette offensive de propagande n'ait pas utilisé de deepfakes, des chercheurs ont découvert que des sous-traitants du Pentagone avaient employé des avatars générés par apprentissage automatique afin de donner à ces faux comptes un certain degré de réalisme. De même, dans un document publié par le *NATO Strategic Communications Center of Excellence* (STRATCOM) (Giles, 2019), l'OTAN envisage les deepfakes comme un outil de guerre de l'information potentiellement central dans les conflits hybrides, et souhaite apprendre à les injecter dans ses propres exercices. Bien que l'OTAN n'ait pas publié de déclaration catégorique indiquant qu'elle s'engage à ne jamais utiliser de deepfakes offensifs, ses documents officiels mettent l'accent sur la compréhension, la prévention et la résilience face à ces technologies, dans le cadre de la protection de la liberté d'expression et des valeurs démocratiques, ce qui suggère qu'elle ne les considère pas comme des outils légitimes d'influence offensive (OTAN, 2025).

Pour conclure, les pays occidentaux commencent eux aussi à envisager sérieusement l'usage de deepfakes dans le cadre plus ou moins offensif d'une lutte informationnelle.

6.2 Utilisation sur le champ de bataille

Alternativement, plutôt qu'un outil de guerre informationnelle prenant place à distance dans un cadre de guerre d'influence, les deepfakes ne peuvent-ils pas être utilisés plus directement sur le terrain ? Les deepfakes seraient alors utilisés comme des leurres. Ainsi, pour appuyer leur offensive sur l'Iran en juin dernier, les États-Unis auraient pu, en plus de leur stratégie de diversion, faire usage de deepfakes pour la rendre encore plus crédible. En effet, grâce à leurs services de renseignement, les services iraniens avaient été mis au courant du départ d'avions B2 américains vers le Pacifique. Il s'agissait en fait d'un simulacre orchestré par la direction des opérations américaines, alors que les avions amenés à bombarder partaient plus tard par l'Atlantique (AFP, 2025). Ainsi, les États-Unis auraient pu poster, à travers de faux comptes bien dissimulés, une vidéo truquée mettant en scène des B2 réalisant un exercice dans le Pacifique, ce qui aurait fait croire aux services iraniens qu'il ne s'agissait pas d'une vraie attaque.

7 Conclusion

Si la lutte contre les deepfakes ne fait que commencer, et malgré le fait que cette arme évolue plus vite que les solutions techniques permettant de s'en défendre, la guerre n'est pas encore perdue. Néanmoins, il est une dimension hautement sensible que nous n'avons pu qu'évoquer brièvement ici : l'éthique. En effet, en matière de régulation de l'information ou d'utilisation offensive des deepfakes, un travail conséquent de réflexion reste à réaliser vis-à-vis des implications sur la démocratie, sur les Droits de l'Homme et sur la légitimité des États occidentaux dans la conduite de la guerre. Si par le passé il a été possible à des États comme la France d'être déployés sur des théâtres d'opérations extérieurs sans difficultés, ce fut en partie grâce à la confiance accordée par les pays hôtes aux valeurs et aux idéaux qu'elle défend. Que se passerait-il s'il fallait renoncer à certains principes moraux pour rééquilibrer le jeu mondial des puissances ? Comment la Nation percevrait-elle alors son propre pays ? Et, de l'intérieur comme de l'extérieur, quels seraient ses soutiens ? Autant de questions qui mériteraient à elles seules un rapport entier, mais qui nécessitent d'être résolues afin que les démocraties occidentales puissent lutter à armes égales avec leurs adversaires.

Références

1. Abdulhamied, E. (2025). *Deepfake audio detection using feature-based and deep learning approaches : ANN vs ResNet50*. International Journal of Advanced Computer Science and Applications.
2. AFP. (2025). *Iran : ce qu'il faut savoir sur les frappes des États-Unis visant trois sites nucléaires*. Le Monde.
3. Barthélemy, L.-P. (2025). *Guerre en Ukraine et deepfakes : un outil discursif, stratégique et systémique*. Revue du Centre de recherche Analyse du discours.
4. Beauvais, C. (2022). *Fake news : why do we believe it ?*
5. Bendiab, E. (2025). *Audio-deepfake : Generation methods, legitimate applications and the potential for misuse*.
6. Biddle, S. (2023). *U.S. Special Forces want to use deepfakes for psy-ops*. The Intercept.
7. Bonnet, F., Fidelin-Durand, G., Guinet, M., Morel, J. & Neveu, C. (2025). *Génération de deepfakes*. ENSTA.
8. Breland, A. (2019). *The bizarre and terrifying case of the "deepfake" video that helped bring an African nation to the brink*. Mother Jones.
9. Byman, D., Gao, F., Meserole, C. & Subrahmanian, V. S. (2023). *Deepfakes and international conflict*. Foreign Policy at Brookings.
10. Cinar, B. (2023). *Deepfakes in cyber warfare : threats, detection, techniques and countermeasures*. Asian Journal of Research in Computer Science.
11. Deromas-Lebocq, I. (2026). *Deepfakes Grok : la France saisit le procureur face à une explosion de contenus sexuels générés par IA*.
12. Desmarais, A. (2025). *Denmark fights back against deepfakes with copyright protection. What other laws exist in Europe ?* Euronews.
13. Fang, L. (2022). *Twitter aided the Pentagon in its covert online propaganda campaign*. The Intercept.
14. Freeman, E. (2025). *The deepfake dilemma : can blockchain restore truth ?* CoinGeek.
15. Giles, K. (2019). *The role of deepfakes in malign influence campaigns*. NATO STRATCOM.
16. Gouvernement français. (2024). *Protect your image rights*.
17. Johnson, A. (2019). *Report on a one-day expert workshop on understanding deepfakes and other forms of synthetic media in Sub-Saharan Africa*. Centre for Human Rights.
18. Kashif-Janjua, D. R. (2025). *Operation Sindoor : Indian media's black propaganda and fake news tactics in the 2025 India-Pakistan conflict*. Pakistan Social Sciences Review.
19. Kazic, T. (2024). *Digital propaganda and disinformation generated via artificial intelligence : the Israel/Palestine conflict and the fall of Bashar al-Assad in Syria*. Center for Strategic Prognosis.
20. Lassere, F. & Aleexeva, O. (2024). *Carte à la une. En mer de Chine méridionale, le jeu politique de l'interprétation du droit de la mer*.
21. Lokhande, M. (2024). *Artificial intelligence for detecting cyber attacks in deepfake and identity theft*. IEEE.
22. Majchrzak, A. (2023). *Russian disinformation and the use of images generated by artificial intelligence (deepfake) in the first year of the invasion of Ukraine*. University of Gdansk.
23. McClain, C. et al. (2025). *How the U.S. public and AI experts view artificial intelligence*. Pew Research Center.
24. ONU Info. (2025). *Les armes à sous-munitions ont fait des centaines de morts et de blessés civils en Ukraine depuis 2022*.
25. OTAN. (2025). *NATO's approach to counter information threats*.
26. Owasp. (2023). *Deepfakes : a growing cybersecurity concern*.
27. Patil, U. (2021). *An effective blockchain technique to resist against deepfake videos*.
28. Rashid, M. M. (2021). *Blockchain technology for combating deepfake and protect video/image integrity*. Journal of Korea Multimedia Society.
29. Rempfer, K. (2019). *SOCOM needs to step up its propaganda game, Pentagon deputy says*. Military Times.
30. Singh, K. (2025). *AI-generative deepfake content used as information war in the post-truth era*. International Journal of Advanced Mass Communication and Journalism.
31. Thomson, H. (2023). *A.I. muddies Israel-Hamas war in unexpected way*. The New York Times.
32. United Nations Office for Disarmament Affairs. (2026).
33. USSOCOM. (2023). *Special operations forces acquisition, technology, and logistics directorate of science and technology (SOF AT&L-ST)*.